



Escuela
Politécnica
Superior

Técnicas de aprendizaje automático aplicadas a la estimación del estado de cultivos mediante series temporales



Grado en Ingeniería en Sonido e Imagen en Telecomunicación

Trabajo Fin de Grado

Autor:

Anaida Fernández García

Tutor/es:

Juan Manuel López Sánchez

Tomás Martínez Marín

Junio 2020



Universitat d'Alacant
Universidad de Alicante

Técnicas de aprendizaje automático aplicadas a la estimación del estado de cultivos mediante series temporales

Autor

Anaida Fernández García

Tutor/es

Juan Manuel López Sánchez

Dpto. de Física, Ing. Sistemas y Teoría de la Señal

Tomás Martínez Marín

Dpto. de Física, Ing. Sistemas y Teoría de la Señal



Grado en Ingeniería en Sonido e Imagen en Telecomunicación



Escuela
Politécnica
Superior



Universitat d'Alacant
Universidad de Alicante

ALICANTE, Junio 2020

Justificación y Objetivos

“Las razones que me han llevado a realizar este Trabajo Fin de Grado (TFG) son colaborar en una investigación en la que el Departamento de Física, Ingeniería de Sistemas y Teoría de la Señal de la Escuela Politécnica Superior lleva trabajando más de 6 años con amplias expectativas de futuro, profundizar mi conocimiento sobre área de las Telecomunicaciones que engloba los sistemas radar y las comunicaciones vía satélite y, por último, adentrarme en las tecnologías emergentes que tanta repercusión van a tener en nuestra vida como son las técnicas de aprendizaje automático o Machine Learning (ML).”

Agradecimientos

Es a ellos a quien dedico este trabajo.

dedicatoria

*La distancia, que es el impedimento principal del progreso de la
humanidad, será completamente superada, en palabra y acción.
La humanidad estará unida, las guerras serán imposibles,
y la paz reinará en todo el planeta.*

Nikola Tesla.

Índice general

1	Capítulo 1. Introducción	1
1.1	Contexto	1
1.2	Objetivos	2
1.3	Estructura de la memoria	2
2	Capítulo 2. Marco Teórico	5
2.1	Teledetección	5
2.1.1	Tecnología radar	5
2.1.2	Satélites en teledetección	8
2.2	Técnicas de regresión y Machine Learning	9
2.2.1	Clasificación de técnicas de Machine Learning	10
2.2.2	Modelos de Machine Learning	11
2.3	Estimación de parámetros físicos de cultivos mediante teledetección	13
2.3.1	Metodología general basada en espacio de estados	14
2.3.2	Regresión aplicada a la estimación	16
	Bibliografía	19
	Lista de Acrónimos y Abreviaturas	21

Índice de figuras

2.1	TOPS-SAR Sentinel-1 [1]	7
2.2	Swath a día 1 de 6 en Sentinel-1 [2]	9

Índice de tablas

Índice de Códigos

1 Capítulo 1. Introducción

La telecomunicación se puede definir como toda transmisión y/o emisión y recepción de señales que representan signos, escritura, imágenes y sonidos o información de cualquier naturaleza por hilo, radioelectricidad, medios ópticos u otros sistemas electromagnéticos [3]. Esto permite compartir información útil a distancia y engloba un amplio conjunto de sistemas y tecnologías.

En este apartado nos vamos a centrar en situarnos dentro de los distintos sistemas de telecomunicación, y más detenidamente en los relevantes para este proyecto. A continuación, se expondrán los objetivos concretos que se quieren alcanzar. Y, por último, cómo se va a organizar la memoria del proyecto.

1.1 Contexto

Las telecomunicaciones forman parte de nuestro día a día y tienen cometidos de lo más variados: desde mandar un simple mensaje hasta comunicarse con una estación espacial, pero todos ellos engloban el manejo o el hecho de compartir información a distancia.

Dentro de los sistemas de telecomunicación encontramos el sistema de la teledetección, definido como la adquisición de información de un objeto, área o fenómeno, con instrumentos que no están en contacto directo con el objeto, según la Real Academia de Ingeniería (RAI) [3]. Estos instrumentos van a medir la radiación electromagnética que emiten o reflejan los objetos observados. Algunos instrumentos pueden ser, por ejemplo, las cámaras fotográficas o los sistemas de radar (RAdio Detection And Ranging) o sonar.

Las imágenes obtenidas desde satélite por sistemas radar son una gran fuente de información para aplicaciones de teledetección, como, por ejemplo, las predicciones meteorológicas, la realización de mapas topográficos o la monitorización de cultivos. Esta última, en la que se va a centrar este proyecto, requiere disponer de suficiente información periódica durante el tiempo que engloba el desarrollo completo del cultivo. En la monitorización de cultivos se encuentra la estimación del estado de los mismos, así como de variables descriptoras de este estado (biomasa, altura, etc.), que se obtienen a partir de imágenes que pueden ser analizadas de forma independiente o utilizando técnicas que aprovechen las series temporales de datos para la estimación. Estas técnicas son muy útiles en estos casos en los que la estimación va estrechamente ligada al transcurso del tiempo.

En la Universidad de Alicante (UA), el grupo de investigación Señales, Sistemas y Telecomunicación (SST) ha diseñado un marco de trabajo sobre este tema basado en espacio de estados, que permite combinar de forma óptima los modelos de evolución esperable de los

cultivos con los datos de otras fuentes como las imágenes Synthetic Aperture Radar (SAR) de satélite o la temperatura acumulada medida por una estación meteorológica.

Hasta la fecha, el modelo de observación utilizado que relacionaba las observaciones proporcionadas por las imágenes SAR con el estado fenológico de los cultivos era bastante simplificado y sus resultados no eran óptimos. Aquí entra el propósito de este TFG, contribuir a su optimización mediante la generación de modelos de observación más complejos para las imágenes SAR. Estos modelos están basados en regresión con técnicas de machine learning que introduzcan la información de estas imágenes en el modelo de espacio de estados mencionado previamente.

1.2 Objetivos

El objetivo general de este TFG es estimar el estado de cultivos de arroz mediante el análisis series temporales con técnicas de aprendizaje automático y su unión a la línea de procesamiento original.

Los objetivos concretos serían:

- Analizar las posibles técnicas de regresión de aprendizaje autónomo (por ejemplo, regresión con Random Forest (RF)) para estimar directamente el estado de los cultivos a partir de series temporales de datos.
- Analizar las posibles técnicas de aprendizaje autónomo para ser combinados con algoritmos ya disponibles de dinámica de sistemas en la estimación del estado de cultivos.
- Incorporar dichas técnicas en la cadena de procesado disponible.

1.3 Estructura de la memoria

La estructura de la memoria se va a dividir en 3 capítulos principales las cuales son: marco teórico, metodología y resultados. Además de unas conclusiones finales valorando los resultados obtenidos.

En el marco teórico se expondrá toda la teoría necesaria para la comprensión de este proyecto en términos técnicos y dentro de un contexto y una investigación previa que este continúa. Veremos en él 3 secciones:

- Teledetección, incluyendo cómo funcionan los sistemas radar, en concreto los SAR, qué información obtenemos de ellos en ciertos programas de satélites y las técnicas de detección que determinan cómo interpretar esta información.
 - Técnicas de regresión y Machine Learning, donde se encuentra la clasificación de las distintas técnicas de ML, algunos modelos y sus aplicaciones existentes, y, por último, el análisis mediante regresión.
-

- Estimación de parámetros físicos de cultivos mediante teledetección, donde se presentan la metodología general basada en el espacio de estados, los parámetros físicos de los cultivos con los que se puede trabajar y la estimación de estos mediante regresión.

En cuanto a la metodología, se incluirán tanto las técnicas y métodos concretos que se van a utilizar, por qué motivos y qué esperamos obtener de ellos, como el software, el lenguaje de programación que vamos a emplear, las herramientas utilizadas y las bases de datos con las que vamos a trabajar, incluyendo su procedencia y procesamiento previo.

Por último, el apartado de resultados expondrá los resultados obtenidos con las diferentes técnicas de regresión y aprendizaje automático para los mismos datos. Estos resultados podrán ser fácilmente evaluados ya que se contrastarán, además, con los datos reales tomados en tierra de los mismos cultivos que se presentan en el dataset.

2 Capítulo 2. Marco Teórico

A continuación se expone la teoría necesaria para la comprensión de este TFG, ampliando la información presentada en el capítulo 1.

2.1 Teledetección

Conociendo de qué trata este sector de las telecomunicaciones de una manera general y en el contexto en el que se sitúa la contribución de este TFG, en este apartado se van a explicar conceptos más concretos de cómo funciona y cómo va a ser utilizada esta tecnología en el proyecto.

Como ya se menciona en el capítulo 1, los instrumentos de teledetección se caracterizan por medir la radiación electromagnética emitida o reflejada por un objeto o superficie que se encuentra a distancia del mismo. Estos instrumentos se pueden clasificar en dos tipos: pasivos, miden la radiación natural emitida o reflejada por el objeto observado, o activos, emiten energía que posteriormente será reflejada y detectada.

Algunos de estos instrumentos son cámaras fotográficas, láseres o radares. Todos ellos trabajan en un determinado rango en el espectro electromagnético, dependiendo de lo que quieran captar, por ejemplo los sensores ópticos necesitan trabajar en frecuencias del espectro visible, mientras que los radares pueden trabajar a frecuencias de microondas.

2.1.1 Tecnología radar

Para este proyecto nos vamos a centrar en el instrumento llamado radar. Se trata de un instrumento activo, que trabaja en el espectro de las microondas, concretamente entre 1-40 GHz. Por ello, son sensores sensibles a objetos del tamaño de sus longitudes de onda, es decir entre 30-0.75 cm, mucho mayores que los sensores ópticos. Además, otras ventajas frente a estos es su penetración en nubosidades e incluso parcialmente en la superficie terrestre o la vegetación, por lo que, por ejemplo, el tiempo atmosférico, no supone un impedimento para la captación de información en la mayoría de los casos, como sucede en los sensores ópticos, y esto también se debe a la mayor longitud de onda.

Al tratarse de un instrumento activo, este también ilumina con pulsos electromagnéticos el área a observar, emitidos por una antena propia, por lo que no depende de fuentes externas de radiación, esto es que, incluso objetos que no emitan radiación ni reflejen de otras fuentes, se podrán detectar gracias a la reflexión de esta incidencia.

La información que se obtiene en una antena receptora (o la misma emisora con doble función) de esta reflexión es otra onda electromagnética de la cual se puede medir su potencia,

fase y polarización para obtener información útil del área observada. Para todas ellas deben tenerse en cuenta parámetros adicionales que influyen durante el trayecto del pulso, como es el retardo de fase o las pérdidas de potencia. El producto típico que esto genera se conoce como imagen SAR, es una representación gráfica cuyo eje horizontal corresponde al azimuth y el eje vertical al rango o distancia, y se presentan, normalmente en escala de grises, las contribuciones para cada “pixel”, siendo el blanco la máxima y el negro la mínima. También se puede representar de igual manera la fase, en escala de grises o color, repartidos entre los 0-360°. *INTRODUCIR IMAGEN SAR*

La potencia recibida (P_R) se puede considerar como la contribución de los siguientes parámetros: potencia transmitida (P_T), longitud de onda (λ), ganancia de la antena (G), pérdidas en sistema (L_s) y en atmósfera (L_a), la longitud del trayecto (R), la superficie del área observada (S) y, por último, el coeficiente de backscattering (σ_0), teniendo en cuenta ambos trayectos de ida y vuelta y la propagación esférica de la onda, como se muestra en la fórmula 2.1.

$$P_R = \frac{P_T \lambda^2 G^2 \sigma_0 S}{(4\pi)^3 L_s L_a R^4} \quad (2.1)$$

Como podemos observar, el parámetro más interesante que nos va a dar información sobre el área observada es el coeficiente de backscattering. Este parámetro es un valor adimensional (dB) que representa la relación entre la proporción de área equivalente si el objeto observado fuera un blanco isótropo (reflexión total) (m^2) y su área o superficie observada real (m^2). Este parámetro va a depender de la frecuencia utilizada por el radar, la polarización de la onda, el ángulo de incidencia del pulso y del material y geometría de la superficie observada. Teniendo en cuenta solamente el coeficiente de backscattering y la longitud de onda empleada (λ), ya existen ciertos rangos que suelen representar distintos tipos de superficies observadas:

- $\sigma_0 > 0$ dB: típicamente objeto artificial liso que está encarado al ángulo de incidencia del radar y actúa como un espejo.
- $-10 \text{ dB} < \sigma_0 < 0$ dB: superficies muy rugosas como pueden ser vegetaciones densas donde hay mucha probabilidad de reflexión.
- $-20 \text{ dB} < \sigma_0 < -10$ dB: superficies rugosas como vegetaciones menos densas entre las que se incluirían los cultivos.
- $\sigma_0 < -20$ dB: superficies lisas que no encaran el haz de incidencia del radar por lo que reflejan casi todo a otra dirección, esto se da en masas de agua en calma, carreteras o suelos muy secos.

Por otra parte, existen técnicas de detección más complejas que consideran también la información proveniente de la fase y la polarización para el desarrollo de modelos. Los principales son la interferometría, la interferometría diferencial y la polarimetría.

Con el objetivo de maximizar la resolución espacial del área observada por el radar, esto es, la distancia mínima distinguible, se necesita mejorar la resolución en rango y en azimuth. La

resolución en rango depende del tamaño del pulso, ya que los objetos podrán ser diferenciados si están a una distancia mayor que un pulso, por lo que cuánto más pequeño sea este, mayor resolución de rango se obtendrá, aunque se debe mantener la duración del pulso para el rango de frecuencias asignado. Por otra parte, para mejorar la resolución en azimuth, se debe incrementar la resolución angular. Esta resolución es inversamente proporcional al ángulo de observación, ya que cuanto mayor es este, más objetos o áreas considera a la misma distancia y no es posible diferenciarlos. Para obtener ángulos pequeños se necesita un swath, o haz de área iluminada, muy directivo, y ello se consigue con una apertura o longitud de radar grande. Es aquí donde entran los sistemas radar de los que se va a extraer la información para este proyecto, los SAR. Estos sistemas consiguen aumentar la resolución en azimuth, con una longitud no muy grande, realizando un barrido en azimuth y posterior procesamiento para ampliar el área observada sin compensar empeorando la resolución en azimuth. Un ejemplo de este barrido se puede ver en la figura 2.1.



Figura 2.1: TOPS-SAR Sentinel-1 [1]

Además de la resolución espacial, también existen otros parámetros que determinan la calidad de la información adquirida por los sistemas radar. Uno de ellos es el ruido que

aparece como puntos de máximas y mínimas contribuciones debido a fenómenos puntuales que puede dificultar la interpretación de la información. Este ruido se denomina speckle, y la técnica utilizada para atenuar este efecto es la reducción por multi-look. Como su nombre indica, esta técnica se basa en la toma de varias imágenes de información de la misma área y el posterior promediado todas ellas, obteniendo una información más plana, viéndose reducidos los píxeles de información aleatorios máximos y mínimos.

2.1.2 Satélites en teledetección

Los sistemas SAR van a ser utilizados en este proyecto para observar parcelas cultivadas de la Tierra, por lo que los sistemas en los que se van a emplazar estos son los satélites. La misión satelital de la que se va a obtener información es Sentinel-1, del Programa Copérnico de la European Space Agency (ESA). Es una misión de órbita polar que engloba 2 satélites, A y B, cuyo objetivo es la observación de la superficie de la Tierra tanto terrestre como oceánica. Sentinel-1 concluyó sus lanzamientos de satélites en abril de 2016. El rango de frecuencias de trabajo de Sentinel-1 proporciona información de la banda C, esto es entre 4-8 GHz, aunque, del mismo programa, la misión Sentinel-2 utiliza tecnología multiespectral, esto significa que trabaja en 13 bandas distintas, las cuales engloban la luz visible, el infrarrojo cercano y el infrarrojo de onda corta. Esto proporciona información más precisa y adecuada para cada fenómeno a observar [4], lo cual puede ser utilizado para futuros avances de esta investigación.

La órbita se traza en el eje polar de la Tierra con una pequeña inclinación y sincrónica al Sol, un periodo de revista global de 6 y una altitud de 693 km para Sentinel-1 ambos satélites, A y B. En la figura 2.2 se puede observar la órbita trazada por Sentinel-1 en un periodo de un día. Además, el sistema SAR no trabaja desde una posición perpendicular a la superficie terrestre a medir, ya que algunas superficies serían consideradas a la misma distancia por simetría en el swath, por lo que la visión del radar es lateral derecha. Esto deberá ser considerado para el procesamiento de extracción de información.

Sentinel-1 tiene 4 modos de adquisición principales según el área que se pretende observar cuyos swath y resolución espacial varían. El primer modo, llamado Stripmap Mode, presenta un swath de 80 km y una resolución de 5x5 m. Este modo se utiliza para monitorización de islas pequeñas y emergencias puntuales. El segundo modo es Interferometric Wide Swath, de 250 km de swath y 5x20 m de resolución, es utilizado principalmente para todas las áreas de superficie terrestre, tanto áreas habitadas, como zonas montañosas o llanuras (donde se incluyen los cultivos). El tercer modo se conoce como Extra Wide Swath Mode, consta de un swath de 400 km y una resolución de 20x40 m, es utilizado para zonas marítimas, polares o cubiertas de hielo, donde se buscan grandes coberturas y un tiempo de revista corto, ya que, por el eje elegido para su órbita, las zonas polares se cubren en menor tiempo. Por último, cabe destacar el Wave Mode, cuyo swath se caracteriza por considerarse de superficie cuadrada de 20x20 km, y con una resolución de 20x5 m. Este es utilizado para la observación de los océanos [5].

Para que la utilización de estos modos sea posible, se necesita una tecnología SAR acorde con estas necesidades. El radar tiene unas dimensiones en Sentinel-1 de antena de 12.3 m x 0.821 m una vez desplegado. El rango del ángulo de incidencia con respecto a la Tierra es de




Figura 2.2: Swath a día 1 de 6 en Sentinel-1 [2]

20"-46". Los modos de adquisición también pueden trabajar con distintas polarizaciones. Las ofrecidas por los satélites de Sentinel-1 para la emisión son Horizontal (H) y Vertical (V). Para la recepción se pueden elegir la misma polarización utilizada en emisión, lo que sería HH o VV, o recibir ambas polarizaciones independientemente de cuál haya sido enviada, HH+HV o VV+VH [5]. Una emisión con polarización doble entorpecería el procesamiento ya que no se podría reconocer en la recepción qué parte de la señal correspondía a cada una.

2.2 Técnicas de regresión y Machine Learning

Las técnicas de regresión proporcionan una estimación de una variable dependiente de otras la cual es útil para realizar predicciones, por lo que están relacionados con el aprendizaje automático o ML. El ML es un tipo de inteligencia artificial, que se caracteriza por la generación de un modelo estimado de manera automática por un computador. Esta estimación se realiza con un entrenamiento previo aplicado a un algoritmo de aprendizaje específico a una serie de datos de entrenamiento. Con este aprendizaje se elabora un modelo que es capaz de devolver una salida o solución a partir de unos parámetros de entrada que deben ser del mismo tipo que los utilizados en la fase de aprendizaje.

* Introducir aquí esquema de ML *

Finalmente, el objetivo de las técnicas de ML puede ser clasificar una información o realizar una previsión acorde con un modelo estimado. Como se puede ver, el objetivo de este y las técnicas de regresión pueden coincidir para el segundo caso, y esto lleva aun desarrollo conjunto de ambas técnicas.

2.2.1 Clasificación de técnicas de Machine Learning

Los modelos empleados en ML son numerosos, y su clasificación se puede realizar dependiendo de su algoritmo de aprendizaje y del tipo de razonamiento en el que se basa. Comenzando por la clasificación según su algoritmo de aprendizaje, que principalmente se dividen según el feedback del que aprenden, los modelos se pueden clasificar de la siguiente manera [6]:

- **Aprendizaje no supervisado:** este aprendizaje se basa en la clasificación o agrupación de los objetos de entrada según patrones que cumplen las distintas entradas de estos. Estos métodos no devuelven un nombre específico para cada grupo o cluster ya que no se le han proporcionado referencias o etiquetas en la etapa de entrenamiento. Necesita numerosas entradas en el entrenamiento para detectar patrones suficientemente estables.
- **Aprendizaje por refuerzo:** el aprendizaje se realiza por refuerzo positivo, que sería una recompensa, o negativo, penalización. Este algoritmo buscaría la estimación del modelo para obtener el máximo refuerzo positivo posible. Así, tras suficiente entrenamiento construye un modelo muy preciso para nuevas entradas.
- **Aprendizaje supervisado:** tanto las entradas como las salidas están previamente definidas en la etapa de aprendizaje. Se realiza un entrenamiento en el que se utilizan las entradas con sus correspondientes salidas para elaborar el modelo. Una vez suficientemente entrenado, este puede obtener salidas previamente desconocidas a partir de entradas similares a las del entrenamiento. Los resultados están limitados a los proporcionados en la etapa de entrenamiento, pero estos suelen ser más estables con menos cantidad de datos que otros modelos.
- **Aprendizaje semi-supervisado:** este aprendizaje recibe algunas de sus entradas correctamente etiquetadas y el resto de ellas, la mayoría, sin etiquetar, así tiene algunas referencias para la clasificación fiables pero no toma las etiquetas como una referencia totalmente cierta para toda la clasificación como ocurre en el aprendizaje supervisado. Así se evitan malos aprendizajes por ruido o etiquetas erróneas en los datos de entrada. Bastante común en grandes masas de datos para aprendizaje.

Por otra parte, teniendo en cuenta la base de los razonamientos internos que los algoritmos realizan para obtener las salidas correspondientes, aunque no considerando esta división estricta, las técnicas se pueden clasificar de la siguiente manera [7]:

- **Geométricos:** los modelos geométricos son aquellos cuyos objetos pueden ser representados en un espacio de instancias (X) en el que cada instancia corresponde a un posible objeto, esto es, habrá tantas instancias como objetos con distintas combinaciones de entradas posibles. Por otra parte, las etiquetas también se representan como un espacio de etiquetas (Y) con un número finito de posibilidades [8]. Utilizando estos conceptos, el algoritmo se desarrolla con otros conceptos geométricos como son líneas, planos y distancias. Estos métodos suelen ser aplicados cuando X e Y están formados por valores numéricos, que son fácilmente representables en ejes de coordenadas.
 - **Probabilísticos:** los modelos probabilísticos parten de la base de que las entradas de los objetos están basadas en un proceso aleatorio que hacen referencia a una distribución
-

de probabilidad desconocida. Se busca definir esa distribución $P(Y|X)$, siendo X el conjunto de objetos posibles e Y las etiquetas correspondientes. Aquí el modelo tendría como salidas probabilidades para cada una de las opciones posibles.

- Lógicos: los modelos lógicos son los más cercanos al razonamiento humano y los más comprensibles también como algoritmos. Se basan en decisiones lógicas, estructuradas típicamente en forma de árbol, esto es llamado árbol de decisiones y según las características de los parámetros de entrada nos vamos desplazando hacia la base del árbol, obteniendo al final una única salida para cada objeto de entrada. *Introducir esquema*
- Agrupaciones y gradiente: estos modelos se incluyen en los anteriores, ya que es una clasificación paralela según el tratamiento del espacio de instancias (X): agrupaciones seccionando estos espacios en un número de segmentos definido, fácilmente representables y con una única solución, en cambio; en los gradientes, no existe una segmentación previamente definida, por lo que el modelo trata todo el espacio como uno solo.

2.2.2 Modelos de Machine Learning

Una vez presentadas todas las posibles clasificaciones de técnicas de ML, podemos adentrarnos en los modelos más comunes, a qué tipo de los anteriores pertenecen y algunas aplicaciones. Algunos de los más conocidos son los siguientes:

- Redes neuronales artificiales: este modelo es de tipo geométrico y de aprendizaje supervisado, ya que el entrenamiento consta de entradas etiquetadas con su correspondiente salida. Este modelo se caracteriza por estar inspirado por las redes neuronales naturales del cerebro animal, obteniendo resultados sin unas reglas preestablecidas de análisis. Estas redes están compuestas por capas de neuronas, las cuales representan un peso y una función de activación por la que una parte de la información de entrada se va a procesar. Estas funciones y pesos se van ajustando mediante el entrenamiento hasta tener una red óptima para su funcionamiento. En cuanto a aplicaciones, la más común es el reconocimiento en imágenes de objetos o caracteres.
- Máquinas de vectores de soporte: es un modelo geométrico y supervisado. Este modelo utiliza el espacio de instancias para representar los objetos de entrenamiento como puntos y las salidas como líneas o hiperplanos, dependiendo del número de dimensiones. Una vez ajustado este modelo, las nuevas entradas se clasificarán según al espacio al que pertenezcan. Este modelo está muy relacionado con la clasificación/agrupación y la regresión. Algunas de sus aplicaciones son la clasificación de textos [9] o, el más interesante para este proyecto, la clasificación de información procedente de un SAR [10].
- Redes bayesianas: es un modelo probabilístico y gráfico, a la vez que lógico, de aprendizaje supervisado. Se basa en un modelo gráfico de nodos que corresponden a variables conocidas o desconocidas y el tratamiento probabilístico simplificado con la regla de la cadena. Son muy utilizadas en aplicaciones relacionadas con las ciencias de la salud para modelar comportamientos biológicos.

- Árboles de decisión: es un modelo lógico y de aprendizaje supervisado. Es lo de los modelos lógicos más ilustrativos porque se basa en árboles que siguen las reglas de decisión, yendo desde el primer nodo donde se sitúa la entrada resolviendo condiciones de estas hasta llegar a una única salida, alcanzable por un camino único, que es la salida del modelo. En el aprendizaje, este modelo va ajustando sus condiciones y elaborando el árbol más coherente para llegar a las soluciones necesarias. Este método es bastante sencillo de implementar y comprender. Relacionado con ese modelo también encontramos el conocido como RF. Este modelo se caracteriza por generar numerosos árboles de decisión provenientes de un factor aleatorio con la misma distribución. Al obtener los resultados de cada uno de los árboles, se realiza un promediado, tomando la respuesta más repetida como la más probable pero teniendo la posibilidad de considerar el resto de salidas en su correspondiente porcentaje. De esta manera, un modelo que era limitado a una respuesta única, se abre devolviendo una respuesta probabilística. Este tipo de respuesta es especialmente interesante para la inclusión de estas estimaciones con datos de otros modelos predictores, ya que no excluye el resto de estimaciones.
- Las técnicas de regresión: son todas aquellas técnicas, típicamente de aprendizaje supervisado, que buscan la relación de una variable dependiente con una o más variables independientes mediante la estimación de su función de regresión. Para ello se consideran y ponderan todos los valores de la variable dependiente para unos valores fijos de las variables independientes. Además, en estos análisis, también se puede tener en cuenta la varianza de la variable dependiente para estos mismos valores, pudiendo ser estudiada también mediante su distribución de probabilidad. Esta varianza indica la fiabilidad de nuestras estimaciones o el “ruido” en las medidas de la variable dependiente. En general, estas técnicas ajustan una función de regresión, por lo que se aplican cuando las variables tienen sentido numérico. Además, estas pueden ser combinadas con otros modelos, como los conjuntos de árboles de decisiones de regresión, conocido como Random Forest Regressor (RFR).

Ya que las técnicas de regresión pretenden modelar una función para una variable, a partir de otras conocidas, este va a ser el método más conveniente para realizar las predicciones del estado fenológico de los cultivos. El caso más sencillo de regresión es en el que solo tenemos una variable dependiente y otra independiente, este caso se conoce como regresión lineal simple, ya que la función de regresión estimada se corresponde a una ecuación lineal de una recta. Los datos que obtenemos para la variable dependiente que vamos a relacionar tienen, aparte de las componentes lineales, una componente aleatoria de ruido que puede deberse a distintos fenómenos como la precisión mínima del instrumento de medida, el ruido que este mismo genera en la medida o contribuciones de fuentes externas, consideradas como ruido también. Esta función de regresión es frecuentemente estimada mediante el Método de Mínimos Cuadrados (MMC). También existe la regresión lineal múltiple, que funciona de la misma manera pero con mayor número de variables independientes, por lo que en lugar de una recta, la función de regresión representa un plano en el que coinciden N dimensiones, siendo N el número de variables independientes total. Su expresión analítica se presenta en la ecuación , donde Y corresponde a la variable dependiente, X a las variables independientes, β parámetro de influencia de cada variable independiente, y ε el término aleatorio.

$$Y_t = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_N X_N + \varepsilon \quad (2.2)$$

Cuando la función de regresión no es una función lineal, la regresión es no lineal, ya que la respuesta de la variable dependiente puede ser exponencial, logarítmica o polinomial, entre otras, por lo que la función de regresión presentará mayor complejidad. Aquí también es común utilizar el MMC o la regresión segmentada, que ajusta como regresión lineal segmentos de la original no lineal.

Cualquier variable independiente que tenga relación con la dependiente es útil en mayor o menor medida pero siempre proporciona información aunque su varianza sea muy grande o su contribución relativamente pequeña. Cualquier tipo de información extra proporciona un ajuste a la estimación final positivo si esta se ha modelado correctamente.

Introducir aquí parte analítica regresión no lineal

A parte de las regresiones lineales y no lineales mencionados, también encontramos otros métodos de regresión como son los mínimos errores absoluto (bastante similar al MMC), la regresión no paramétrica o la regresión lineal bayesiana.

2.3 Estimación de parámetros físicos de cultivos mediante teledetección

La fenología es la ciencia que estudia la relación entre los factores climáticos y los ciclos de los seres vivos [11]. Esto es, el estudio del desarrollo de plantas y animales en relación con parámetros ambientales. Este proyecto se centra en el estudio fenológico de plantas, en concreto de cultivos de arroz. Por lo que, a continuación, se van a presentar los conceptos físicos que definen el estado de desarrollo de estos cultivos, para comprender cuáles son los parámetros clave y utilizados en el marco de investigación. Una vez introducidos, se expone el concepto de la técnica utilizada hasta el momento, los modelos de evolución y observación. Por último, se verá la aplicación de las técnicas de regresión a los datos obtenidos para elaborar un modelo representativo del estado fenológico de un cultivo.

Algunos de los parámetros descriptores clave utilizados en el marco creado de este proyecto son los siguientes:

- Escala Biologische Bundesanstalt, Bundessortenamt und Chemische Industrie (BBCH), que recibe su nombre por los participantes en su estudio y desarrollo, es una escala numérica de intervalo 0-9 que describe la fenología [12]. Cada valor numérico corresponde a un estado de desarrollo, desde la germinación o primeros brotes, correspondientes al estado 0, hasta la senectud, estado 9. Cada estado puede estar dividido hasta en 10 sub-etapas. El rango de que cada etapa abarca, concretamente para los cultivos de arroz, se puede observar en la tabla *insertar tabla* [13]. Para que uno de estos estados sea considerado el nivel general de una parcela, no solo tiene que ser este estado el mayoritario, sino que debe abarcar más del 50% del cultivo.

- Índice de Vegetación de Diferencia Normalizada (NDVI), enunciado anteriormente, es un observable proporcionado por los sensores ópticos que suele ser usado como índice de vegetación de diferencia normalizada, para estimar la cantidad, calidad y desarrollo de la vegetación con base a la medición de la intensidad de la radiación de ciertas bandas del espectro electromagnético en ella. Estas bandas son concretamente las bandas del rojo y del infrarrojo cercano, con rangos de reflexión entre 0 y 1 cada una de ellas. El coeficiente $glsndvi$ se obtiene según la fórmula 2.3, conformando un rango entre -1 y 1, y representa el desarrollo de la vegetación, ya que la contribución de la banda infrarroja cercana está ligada a la reflexión de la celulosa, por tanto a las áreas verdes y frondosas, mientras que la banda roja es mucho menos sensible a estas contribuciones y más a la absorción de clorofila. En resumen, un buen desarrollo vegetal tiene valores de NDVI más cercanos a la unidad positiva [14].

$$NDVI = \frac{IRCercano - ROJO}{IRCercano + ROJO} \quad (2.3)$$

- Temperatura del aire, o el calor acumulado durante todo el proceso de desarrollo de un cultivo, es una fuente de observaciones para el que existen modelos de observación que lo relacionan con el estado fenológico. Concretamente en los cultivos de arroz tiene un impacto notable, por lo que se considera otro de los parámetros a tener en cuenta en su monitorización y en la elaboración de modelos de predicción [15].

2.3.1 Metodología general basada en espacio de estados

En este área hay estudios previos donde se crea la metodología basada en espacio de estados utilizada. El primer artículo [16] de este marco de trabajo, de 2014, trata de estimar el estado fenológico de cultivos en tiempo real empleando espacio de estados y técnicas de sistemas dinámicos utilizando información del pasado y actualizaciones. Esto se ve representado por dos modelos diferenciables, los cuales son el modelo de evolución: modelo que predice el estado fenológico de un cultivo según el desarrollo cronológico típico del mismo, y el modelo de observación: modelo que trata de predecir el estado de fenológico a partir de variables físicas observables. Estos modelos son combinados para considerar tanto el desarrollo habitual de un cultivo como posibles variaciones temporales (adelantos o retrasos) en el mismo que pueden ser debidos a múltiples factores.

Dentro del espacio de estados se define que cada etapa de la evolución corresponde a un único estado, el cual está contenido en un sistema dinámico o proceso, ya que tiene una evolución temporal. Este sistema se define según las siguientes ecuaciones, donde la fórmula 2.4 es el proceso recursivo, correspondiente al modelo de evolución, y la fórmula 2.5 es la ecuación de medida, que relaciona una nueva observación con el sistema, por lo que corresponde al modelo de observación.

$$\dot{x}(t) = \frac{dx(t)}{dt} = f(x(t), t, v(t)) \quad (2.4)$$

$$z(t) = h(x(t), t, w(t)) \quad (2.5)$$

El vector de estados $x(t)$ es el vector de n variables de estado que describe el sistema en un momento determinado t , por lo que el espacio de estados dispone de n dimensiones. Las funciones que aportan el ratio de cambio para cada estado está representado por $f()$ y el ruido en la evolución es $v(t)$. $z(t)$ representa el vector de salida, donde $w(t)$ es el ruido, y $h(t)$ la relación entre el vector de estados y la observación $z(t)$.

Las dos etapas en las que se divide este algoritmo son predicción y actualización. La actualización se produce cuando existe información observable nueva, esta se introduce al sistema mediante una Extended Kalman Filter (EKF) y genera un nuevo estado y una matriz de transiciones, la cual representa la probabilidad de los siguientes posibles estados.

Para la creación del modelo de evolución se utilizan los mismo observables polarimétricos (información del radar polarimétrico, vertical (V) y horizontal (H), del satélite Radsat-2) que para las actualizaciones. Los valores de este modelo no son exactamente la escala BBCH ya que no hay un registro continuo para ello pero están discretizados y agrupados en rangos equivalentes a valores fenológicos. Estas agrupaciones o clusters van ajustando su centro con las actualizaciones de los observables. La estimación, entonces, se realiza combinando la información de este modelo, una vez que está generado y conociendo la información temporal del cultivo a estimar, con la información observable por medio del EKF.

En 2016, el marco de trabajo publica otro artículo [15] en el que se trata de estimar el NDVI, siendo este un descriptor del estado fenológico también, de cultivos de arroz a partir de dos fuentes de información observables: imágenes SAR del satélite TerraSAR-X y temperatura del aire registrada, combinadas en tiempo real mediante filtros de partículas. Se mantiene el método de trabajo de espacio de estados con predicción y actualización.

Además de las mejoras que presenta por la consideración de la temperatura como fuente de información, este artículo introduce cómo trabajar con las imágenes SAR. Las imágenes SAR dan una información de el coeficiente de reflexión de la superficie observada, según una polarización de onda emitida y recibida, siendo este representado en ejes de azimuth y rango, como se ha explicado anteriormente. Estas imágenes, de libre acceso por la ESA, cuentan con canales de polarización VV y HH para TerraSAR-X y VV y VH para Sentinel-1, esto último es, emisión vertical y recepción tanto vertical como horizontal. La segunda configuración es más sensible al crecimiento de los cultivos de arroz por la verticalidad de sus tallos. Por otra parte, las imágenes de polarización horizontal recibida proporciona información extra que puede ser útil y que es bastante semejante a la obtenida en HV, es decir, emisión horizontal y recepción vertical, por lo que se abarca la mayor parte de información útil posible. A parte de las distintas polarizaciones, las imágenes SAR obtenidas por el satélite TerraSAR-X son equivalentes a las obtenidas por Sentinel-1, por lo que su marco de trabajo es perfectamente compatible.

Las imágenes SAR pueden ser adquiridas con distintos formatos. El que se va a utilizar aquí es el formato Ground Range Detected (GRD) *¿Resolución?* por conveniencia para este estudio. Este formato consiste en imágenes SAR multi-look (reducción de speckle) y proyectadas al rango de la tierra utilizando un modelo de elipsoide de la Tierra. La información de

la fase es suprimida, lo cual no es un problema, ya que no era uno de los parámetros clave utilizados, y los píxeles que presenta la imagen son aproximadamente cuadrados [17].

El primer problema reconocible en la obtención de estas imágenes es su falta de correspondencia con las coordenadas geográficas comúnmente utilizadas, además de las dimensiones y orientación de estas, ya que las imágenes abarcan áreas de mucho mayor tamaño a las áreas de cultivos aquí estudiados, y la orientación no es totalmente paralela al eje polar de la Tierra, sino que presenta cierta inclinación. Para solucionar todo ello, se realiza un pre-procesado desarrollado por el Departamento de Física, Ingeniería de Sistemas y Teoría de la Señal de la Escuela Politécnica Superior, utilizando el software libre SNAP cedido por la ESA, que se divide en los siguientes pasos:

1. Lectura de las imágenes.
2. Actualización de la información orbital en las imágenes cargadas.
3. Cancelación de ruido térmico.
4. Recorte del área de interés.
5. Calibración radiométrica para obtener de salida de ambos canales (VH y VV) el formato σ_0 .
6. Filtrado de speckle.
7. Conversión de escala lineal a dB.
8. Geo-referenciación: genera un mapa en una rejilla uniforme de coordenadas cartográficas con tamaño de píxel elegido de aproximadamente 10 m para cada coordenada (latitud y longitud).
9. Escritura del producto en formato propio de SNAP: DEAM-DIMAP

Esto se realiza tantas veces como número de imágenes de distintas fechas se hayan obtenido. Para finalizar el procesamiento, se ajustan unas imágenes con otras para que todas estén referenciadas a las mismas coordenadas cartográficas en los mismos píxeles. Una vez finalizado este proceso, las imágenes están preparadas para tratar su información de manera más sencilla.

2.3.2 Regresión aplicada a la estimación

Dentro del marco de trabajo previo, este TFG se va a centrar en elaborar un modelo de observación a partir de las imágenes SAR de los satélites de Sentinel-1, con datos de 2017 y 2018 para cultivos de arroz, haciendo uso de la regresión de series temporales y técnicas de aprendizaje automático. Modelo que posteriormente se combinará con el de evolución para la elaboración de estimaciones más completas y fiables. La regresión busca generar un modelo de predicción del fenómeno que se está estudiando a partir de una información de la que el fenómeno depende. En este caso, ese fenómeno es el estado fenológico de los cultivos de arroz y la información a partir de la cuál se va a generar este modelo son los coeficientes de

backscattering obtenidos para las distintas polarizaciones (VV y VH), su ratio y la desviación estándar de cada uno, todo ello a nivel de parcela y día.

A la hora de crear un modelo a partir de regresión, se debe considerar la evolución que se quiere estudiar para elegir la información que se va a utilizar. Para el estudio de la fenología se debe escoger información que complete un periodo de desarrollo desde el primer estado de la siembra del cultivo, hasta la madurez y recogida del producto, información que debe presentar una resolución temporal suficiente para que sean distinguibles las distintas etapas dentro del proceso. A esto se suma que para la generación de un modelo fiable este tiene que ajustarse con un número determinado de ciclos enteros de información, en mayor o menor número dependiendo de la fiabilidad y constancia de los mismos.

La información con la que se va a trabajar presenta unas limitaciones temporales debido al reciente desarrollo del programa Copérnico. Aún así, parece válida para una aproximación suficientemente fiable. Los datos con los que se cuenta para este proyecto parten del año 2017 en adelante, cuando el periodo de revista de Sentinel-1 ya es de 6 días, con lo que la resolución temporal de cada ciclo es aceptable. Al ser los periodos de cultivo del arroz de aproximadamente 4 meses, se realizan 2 veces al año, número no muy amplio para disponer de suficientes ciclos de crecimiento desde el año 2017 hasta 2018. El alza en el número de periodos para general el modelo recae en la división de la información en distintas parcelas a estudiar, por lo que por cada época de cultivo se dispone de hasta 7 ciclos de desarrollo, número de parcelas observadas, a tener en cuenta para el modelo. En el caso de no disponer de suficiente información, esta se podría generar de manera estadística, partiendo de la original.

Habiendo generado un modelo utilizando técnicas de regresión, este debe ser comparado con información contrastada de los cultivos que indiquen si el modelo se aproxima lo suficiente a la realidad del terreno y, por tanto, es un modelo fiable. Esto significaría que la información utilizada, a priori, tiene relación con el fenómeno estudiado, y que la cantidad de información ha sido suficiente para ajustar el modelo, por lo que puede ser utilizado para predicción, en este caso, del estado fenológico del nuevo cultivo observado.

La técnica de regresión que se va a emplear es RFR, una técnica de aprendizaje automático supervisado basado en árboles de decisión como se ha visto anteriormente y que ha sido probada su eficacia en generaciones de modelos similares para imágenes SAR en 2019 [18]. En este caso, las salidas son los posibles valores de BBCH, a los que se llega mediante decisiones sobre los rangos de valores que presentan los parámetros de entrada. Como todas las técnicas de aprendizaje automático, cuenta con una etapa de aprendizaje para la creación del modelo, y una etapa de test para comprobar su correcto funcionamiento. Normalmente, para cada vector de entrada, este modelo devuelve una salida única que es el estado fenológico más probable, pero por motivos de integración con el modelo de evolución, va a presentar la probabilidad para cada estado.

En este modelo no se incluye la parte dinámica del sistema, ya que esta está representada en el modelo de evolución y, por tanto, en la unión de ambos modelos. Pero este modelo se va a generar únicamente a partir de los observables anteriormente mencionados. Las salidas

de este modelo son funciones de densidad de probabilidad del estado fenológico o BBCH y/o de la altura del cultivo, parámetro físico también íntimamente relacionado con el desarrollo de arroz.

Bibliografía

- [1] ESA. *Sentinel-1: Radar mission*, 2014. URL <https://www.youtube.com/watch?v=FJWzLxdSMYA>.
- [2] ESA. *Sentinel-1 constellation*, 2014. URL https://www.esa.int/Applications/Observing_the_Earth/Copernicus/Sentinel-1/Satellite_constellation.
- [3] DE INGENIERÍA, R.A. *Diccionario español de ingeniería*, 2014. URL <http://diccionario.raing.es/es>.
- [4] ESA. *Copernicus overview*, 2016. URL https://www.esa.int/Applications/Observing_the_Earth/Copernicus/Overview4.
- [5] EARTH OBSERVING SYSTEM (EOS). *Sentinel 1*., 2014. URL <https://eos.com/sentinel-1/>.
- [6] RUSSELL, S.J. and NORVIG, P. *Artificial Intelligence A Modern Approach*, 2010.
- [7] FLACH, P. *Machine Learning: The Art and Science of Algorithms that Make Sense of Data*, 2012.
- [8] FÜRNKRANZ, J. and HÜLLERMEIER, E. *Preference Learning: An Introduction*, 2011.
- [9] JOACHIMS, T. *Text categorization with support vector machines: Learning with many relevant features. Machine Learning: ECML-98. Lecture Notes in Computer Science*, 1998.
- [10] MAITY, A. *Supervised classification of radarsat-2 polarimetric data for different land features. CoRR*, 2016. URL <https://dblp.org/rec/journals/corr/Maity16.bib>.
- [11] CASTILLO, F.E. and SENTÍS, F.C. *Agrometeorología*, 2001.
- [12] MEIER, U. *Growth stages of mono-and dicotyledonous plants. Federal Biological Research Centre for Agriculture and Forestry*, 2001. URL <https://web.archive.org/web/20180427154542/https://ojs.openagrar.de/index.php/BBCH/article/download/515/464>.
- [13] LANCASHIRE, P.D., BLEIHOLDER, H., BOOM, T.V.D., LANGELOUDEKE, P., STAUSS, R., WEBER, E., and WITZENBERGER, A. *A uniform decimal code for growth stages of crops and weeds. Annals of Applied Biology*, 1991.
- [14] VERDIN, J., PEDREROS, D., and EILERTS, G. *Índice diferencial de vegetación normalizado (ndvi). FEWS - Red de Alerta Temprana Contra la Inseguridad Alimentaria, Centroamérica, USGS/EROS Data Center*, 2003.

- [15] BERNARDIS, C.D., VICENTE-GUIJALBA, F., MARTINEZ-MARIN, T., and LOPEZ-SANCHEZ, J.M. *Contribution to real-time estimation of crop phenological states in a dynamical framework based on ndvi time series: Data fusion with sar and temperature*, 2016.
 - [16] VICENTE-GUIJALBA, F., MARTINEZ-MARIN, T., and LOPEZ-SANCHEZ, J.M. *Dynamical approach for real-time monitoring of agricultural crops*, 2014.
 - [17] ESA. *Missions: Sentinel -1. data products*, 2020. URL <https://sentinels.copernicus.eu/web/sentinel/missions/sentinel-1/data-products>.
 - [18] WANGA, H., MAGAGIA, R., GOÏTAA, K., TRUDELA, M., MCNAIRNB, H., and POWERS, J. *Crop phenology retrieval via polarimetric sar decomposition and random forest algorithm*. Elsevier, 2019.
 - [19] DECOSTE, D. and SCHOLKOPF, B. *Training invariant support vector machines*. Kluwer Academic Publishers, 2002.
 - [20] BARGHOUT, L. *Spatial-taxon information granules as used in iterative fuzzy-decision-making for image segmentation*. Granular Computing and Decision-Making, 2015.
-

Lista de Acrónimos y Abreviaturas

AEMA	Agencia Europea de Medio Ambiente.
BBCH	Biologische Bundesanstalt, Bundessortenamt und CHemische Industrie.
EOS	Earth Observing System.
ESA	European Space Agency.
GRD	Ground Range Detected.
ML	Machine Learning.
MMC	Método de Mínimos Cuadrados.
NDVI	Índice de Vegetación de Diferencia Normalizada.
RAI	Real Academia de Ingeniería.
RF	Random Forest.
RFR	Random Forest Regressor.
SAR	Synthetic Aperture Radar.
SST	Señales, Sistemas y Telecomunicación.
TFG	Trabajo Fin de Grado.
UA	Universidad de Alicante.